

Policy Gradient com Actor-Critic (A2C) — Relatório experimental


Autores: Frederico Barbosa Relvas · Henrick de Souza Silva · Fork com `algorithms/a2c.py` e `networks/discrete_actor_critic.py` **completos:** <https://github.com/FredRelvas/t-zero-learning>

CartPole-v1, 500.000 passos, baseline = `configs/a2c_cartpole.yml` sem alterações. O lote é `num_envs × num_steps = 8 × 5 = 40`, o que dá 12.500 atualizações; o baseline chega a retorno 475/486 (seeds 1/2) e avaliação 500 ± 0 . As Q1 e Q2 alteram o lote e portanto também **quantas atualizações cabem** no orçamento fixo de passos. Previsões registradas antes das varreduras em `previsoes_a2c.md`.

Q1 — Número de atores em paralelo

Previsão. Com 1 ambiente o lote cai para 5 transições consecutivas do mesmo episódio, então prevejo `policy_loss` com oscilação várias vezes maior, e que isso não seja compensado pelas 100.000 atualizações que o lote pequeno permite. Prevejo `SPS` saturando depois de 8, pelos 10 núcleos da máquina.

Varredura. `num_envs` $\in \{1, 8, 32\}$, 2 seeds em cada.




Explicação. Os três gráficos separam as configurações de forma limpa. No `policy_loss`, o traço de 1 ambiente fica colado em zero quase o tempo todo e dá picos isolados de ± 50 , enquanto o de 32 oscila numa faixa estreita — o desvio-padrão da série cai $4,45 \rightarrow 1,37 \rightarrow 0,74$ de 1 para 8 e 32 ambientes. No retorno, o baseline está no topo e 1 ambiente embaixo, com as duas seeds bem afastadas. E o `SPS` sobe de 2.655 para 19.531 e 33.085, sem achatar. O mecanismo por trás: um método on-policy não pode usar replay buffer, então a decorrelação que o DQN obtinha no tempo tem de vir do espaço — vários ambientes em fases diferentes de episódios diferentes, que é o argumento central do A3C. Com lote de 5 as transições vêm do mesmo trecho de episódio e têm vantagem quase idêntica, daí o formato intermitente, o mais nocivo possível para o gradiente. Separando os dois efeitos, 1 ambiente faz **8x mais** atualizações que o baseline e ainda assim aprende pior (eval 411 e 256 contra 500/500): a degradação é da *qualidade* de cada passo, não da quantidade. Já 32 ambientes têm o gradiente mais limpo mas só 3.125 atualizações, e terminam abaixo do baseline (eval 500 e 360) — subtreino, como previsto. **A previsão do SPS foi refutada:** não houve saturação nos 10 núcleos, porque o gargalo do CartPole não é a física e sim o custo fixo por passo em Python/torch, que uma passada forward em lote amortiza.

Q2 — Horizonte do retorno de n passos

Previsão. Com `num_steps=1` o alvo é quase todo bootstrap — pouca variância, muito viés —, então prevejo `value_loss` mínimo e `explained_variance` enganosamente alta, porque o alvo vira quase função determinística de $V(s')$ e a métrica mede consistência de um passo, não acerto do valor verdadeiro. Com $n = 128$ prevejo o contrário, mais subtreino pelas 488 atualizações.

Varredura. `a2c.num_steps` $\in \{1, 5, 32, 128\}$, 2 seeds em 1, 5 e 128.





Explicação. O `value_loss` ordena as quatro configurações em patamares bem separados, na ordem do horizonte: $\approx 10^{-5} \rightarrow 18 \rightarrow 160 \rightarrow 410$ para $n = 1, 5, 32$ e 128. A `explained_variance` inverte essa ordem — $n = 1$ é a melhor da varredura (0,81) enquanto $n = 32$ e 128 ficam coladas em zero. E o retorno não segue nenhuma das

duas: o baseline vence, com ambos os extremos abaixo. A leitura conjunta explica o aparente paradoxo. Com $n = 1$ o alvo $r + \gamma V(s')$ é quase o próprio $V(s)$, já que estados adjacentes no CartPole têm valor quase igual: a regressão é trivial e as duas métricas do crítico parecem ótimas. **Isso não significa crítico bom** — o `advantage_std` vale **0,01**, ou seja, o peso do gradiente de política é essencialmente zero. O crítico está consistente consigo mesmo sem informar nada sobre o valor verdadeiro. Na outra ponta ele não consegue acompanhar: com $n = 128$ e 488 atualizações o `advantage_mean` sobe para **+21,6**, sinal de que o retorno excede sistematicamente um $V(s)$ que nunca teve passos para convergir. O ator sofre junto porque a vantagem $R - V(s)$ é o peso do gradiente, e os extremos caem para `eval` 186 ($n = 32$) e 323 ($n = 128$) contra 500 do baseline. **A previsão se confirmou parcialmente**: esperávamos o baseline vencendo os dois extremos, mas $n = 1$ empatou na avaliação (500/500) e perdeu só no retorno de treino (372/402 contra 475/486) — num ambiente de duas ações o sinal minúsculo ainda tinha o sinal algébrico certo, e as 62.500 atualizações bastaram.

Q3 — Coeficiente de entropia

Previsão. Sendo o bônus de entropia o único freio contra o colapso prematuro para uma política determinística, prevejo que com `ent_coef=0` a entropia caia rápido mas o CartPole ainda seja resolvido, com dispersão maior entre seeds. Com 0,1 prevejo entropia presa perto de $\ln 2 \approx 0,69$ e retorno estacionado.

Varredura. `a2c.ent_coef` $\in \{0, 0,01, 0,1\}$, 2 seeds em cada.







Explicação. O gráfico de entropia separa as três configurações em faixas que nunca se cruzam: `ent_coef=0,1` colado no teto de $\ln 2 \approx 0,69$, o baseline em 0,56 e `ent_coef=0` descendo até 0,46 e 0,33. O gráfico de retorno inverte a ordem — 0,1 é o pior (386/305) e `ent_coef=0` o melhor (498/494, **acima** do baseline, que paga o imposto da entropia), com as duas seeds resolvendo o ambiente (`eval` 500/500). O bônus existe para impedir o colapso prematuro, risco específico do gradiente de política: uma ação ligeiramente mais provável é amostrada mais, reforçada mais, e trava antes de as alternativas terem sido testadas. Que o CartPole sobreviva sem ele se deve a três fatores somados: duas ações apenas, de modo que mesmo uma política quase determinística explora metade do espaço por acidente; recompensa densa e positiva em todo passo, de modo que o gradiente nunca fica sem sinal; e uma política boa simples o bastante para ser achada antes de a entropia acabar. Com mais ações ou recompensa rara isso inverteria: o colapso viria antes de qualquer trajetória recompensada ser amostrada e o agente travaria numa região sem sinal. Com `ent_coef=0,1` a previsão se confirmou integralmente — o crítico melhora, as vantagens encolhem, e o termo de entropia, que é constante, passa a dominar o gradiente. O agente está sendo pago para permanecer indeciso.

Q4 — Ablação do baseline

Previsão. Prevejo `advantage_mean` em torno de zero com baseline e fortemente positivo sem ele (o retorno de 5 passos vale $\approx 4,9 + 0,95 \cdot V(s)$), com `advantage_std` muito maior. Como todo peso fica positivo, **toda** ação amostrada é reforçada, o que deve gerar realimentação de "rico fica mais rico" e colapso de entropia. Prevejo ainda que `max_grad_norm=0,5` clipe quase todo passo.

Varredura. `a2c.use_baseline` $\in \{\text{true}, \text{false}\}$, 2 seeds em cada.



Explicação. Os quatro gráficos contam a mesma história em quatro tempos. O `advantage_mean` oscila em torno de zero com baseline ($-0,37$ e $-1,72$) e sobe para um patamar de **+27,7 e +38,3** sem ele; o `advantage_std` acompanha, de 1,9 para **14,1**; a entropia despenca de 0,56 para **0,002**, política praticamente determinística; e o retorno cai de 475 para **69**. A teoria prevê exatamente o primeiro par: subtrair um baseline que dependa só do estado não altera o gradiente esperado, porque $E[\nabla \log \pi(\text{als}) \cdot b(s)] = b(s) \cdot \nabla \sum \pi(\text{als}) = b(s) \cdot \nabla 1 = 0$ — altera apenas a variância. Mas a consequência é de atribuição de crédito, não só de ruído: no CartPole toda recompensa é +1, logo todo retorno é positivo, e um retorno de 80 tanto pode ser ótimo (estado valia 40) quanto péssimo (estado valia 95) — sem subtrair $V(s)$ os dois empurram a log-probabilidade para cima com a mesma força. Como as ações são amostradas na proporção da probabilidade atual, a que está na frente é reforçada mais vezes e a realimentação se fecha, o que explica o colapso de entropia do terceiro gráfico. O clipping agravou o quadro: pesos de ordem 30 contra ~ 1 do baseline mantêm o gradiente saturado em `max_grad_norm=0,5` quase o tempo todo. Vale registrar o achado mais instrutivo da varredura: sem baseline a `explained_variance` marca **1,00** e o `value_loss` cai para 0,34 — os dois gráficos do crítico parecem perfeitos enquanto o agente tira 69 de 500, porque a política colapsada produz episódios curtos e quase idênticos e prever um retorno constante é trivial. É a lição da atividade anterior por um mecanismo novo: **nenhuma métrica de perda deve ser lida isoladamente.**